Εργασία 2 - Επεξεργασία Φυσικής Γλώσσας (Word Embeddings & Traditional VS RNN-LSTM Text Classification)

Φαίδων Γραμματικόπουλος

Μάθημα: Επεξεργασία Φυσικής Γλώσσας
Διδάσκων: Ε. Σταματάτος

MSc in Artificial Intelligence
University of Piraeus & NCSR "DEMOKRITOS", Greece

Απρίλιος 2026

Εισαγωγή

Στην παρούσα εργασία μελετώνται τρεις θεμελιώδεις πτυχές της Επεξεργασίας Φυσικής Γλώσσας (NLP):

- Πυκνές διανυσματικές αναπαραστάσεις λέξεων (word embeddings)
- Παραδοσιακή ταξινόμηση κειμένου με μοντέλα μηχανικής μάθησης
- Ταξινόμηση κειμένου με νευρωνικά δίκτυα ανατροφοδότησης (RNN / LSTM)

Στο **Μέρος Α** αξιοποιούνται τα προ-εκπαιδευμένα word embeddings *word2vec-google-news-300* και *glove-wiki-gigaword-300* του gensim για τη μελέτη σημασιολογικών σχέσεων μεταξύ λέξεων. Συγκεκριμένα, εξετάζονται οι κοντινότερες λέξεις σε επιλεγμένες λέξεις-στόχους, αναλύεται η συμπεριφορά των δύο μοντέλων σε φαινόμενα πολυσημίας, υπολογίζονται γειτονιές με ή χωρίς εξαίρεση συγκεκριμένων εννοιών (μέσω αλγεβρικής αφαίρεσης διανυσμάτων αλλά και φιλτραρίσματος συνημίτονης ομοιότητας), επιλύονται αναλογίες της μορφής $\vec{a} - \vec{b} + \vec{c}$ και τέλος οπτικοποιούνται σε δύο διαστάσεις, μέσω t-SNE, οι σχέσεις 28 επιλεγμένων λέξεων.

Στο **Μέρος Β** εφαρμόζονται τέσσερα παραδοσιακά μοντέλα ταξινόμησης κειμένου: Multinomial Naïve Bayes και Linear SVM, καθένα με αναπαράσταση *tf-idf* είτε σε επίπεδο word uni-grams είτε σε επίπεδο character tri-grams --- στο *AG News Topic Classification dataset* (4 κατηγορίες: World, Sports, Business, Sci/Tech, με 120.000 παραδείγματα εκπαίδευσης και 7.600 παραδείγματα αξιολόγησης). Συγκρίνεται η επίδοση (accuracy), η διάσταση της αναπαράστασης και ο χρόνος εκπαίδευσης κάθε μοντέλου, και πραγματοποιείται ανάλυση σφαλμάτων στα κείμενα που ταξινομούνται λανθασμένα από όλα τα μοντέλα ταυτόχρονα.

Στο **Μέρος Γ** υλοποιούνται έξι παραλλαγές αναδρομικών νευρωνικών δικτύων (RNN, LSTM) στο PyTorch και αξιολογούνται στο ίδιο dataset (AG News). Για κάθε αρχιτεκτονική παρουσιάζονται μέση επίδοση (mean accuracy) και τυπική απόκλιση πάνω σε 3 ανεξάρτητες εκτελέσεις, αριθμός εκπαιδεύσιμων παραμέτρων και χρονικό κόστος ανά εποχή. Επιπλέον, συγκρίνεται το χρονικό κόστος εκπαίδευσης μεταξύ CPU και επιταχυντή (Apple-MPS), οπτικοποιούνται μέσω t-SNE τα word embeddings που μαθαίνει το ίδιο το δίκτυο (ώστε να συγκριθούν με τα προ-εκπαιδευμένα του Μέρους Α), εξετάζεται η επίδραση της αύξησης του μήκους ακολουθίας από 25 σε 50 tokens, η αρχικοποίηση των embeddings από το *glove-wiki-gigaword-100* με ή χωρίς δυνατότητα fine-tuning (frozen vs trainable), καθώς και η εφαρμογή ολόκληρου του πλέγματος πειραμάτων στο *IMDB movie reviews dataset* (50.000 κριτικές, 80/20 split).

Ο κώδικας υλοποιήθηκε σε Python και είναι διαθέσιμος στο ανοικτό αποθετήριο στο github: [https://github.com/Fgram-devAI/nlp-ncsr-task2].

Κεφάλαιο 1

Μέρος Α — Word Embeddings

1.1 Α.1 Οι 10 πιο κοντινές λέξεις για *car*, *jaguar*, *Jaguar*, *facebook*

Για κάθε λέξη παρατίθενται οι top-10 γείτονες σύμφωνα με το *word2vec-google-news-300* και το *glove-wiki-gigaword-300*, μαζί με το πλήθος των κοινών λέξεων στις δύο λίστες.

Λέξη	**word2vec (top-10)**	**GloVe (top-10)**
car	vehicle, cars, SUV, minivan, truck, Car, Ford_Focus, Honda_Civic, Jeep, ...	cars, vehicle, truck, driver, driving, vehicles, motorcycle, automobile, ...
jaguar	jaguars, Macho_B, panther, lynx, rhino, lizard, tapir, tiger, leopard	rover, bmw, mercedes, sepecat, mustang, lexus, volvo, cosworth, ...
Jaguar	Land_Rover, Aston_Martin, Mercedes, Porsche, BMW, Bentley_Arnage, ...	*OOV* (το λεξιλόγιο GloVe είναι αποκλειστικά πεζά γράμματα)
facebook	Facebook, FaceBook, twitter, myspace, Twitter, twitter_facebook, ...	twitter, myspace, youtube, blog, linkedin, google, website, ...

Κοινές λέξεις: *car* = 3/10 (vehicle, cars, truck), *jaguar* = 0/10, *Jaguar* = 0/10 (OOV στο GloVe), *facebook* = 3/10 (twitter, myspace, linkedin).
Παρατηρήσεις.

- Για το *car* τα δύο μοντέλα συμφωνούν στη βασική σημασία (όχημα): υψηλή σημασιολογική συμφωνία.
- Το *jaguar* αποκαλύπτει μία **χαρακτηριστική περίπτωση πολυσημίας**: το word2vec επιστρέφει το *ζώο* (λόγω του corpus των ειδήσεων), το GloVe το *αυτοκίνητο* (λόγω του Wikipedia/Gigaword corpus). Μηδενική επικάλυψη.
- Το *Jaguar* (κεφαλαίο) είναι OOV στο GloVe — το λεξιλόγιο του είναι μόνο πεζών γραμμάτων. Στο word2vec, η διατήρηση του case λειτουργεί ως μηχανισμός αποσαφήνισης (επιστρέφει μάρκες αυτοκινήτων).
- Το *facebook* συγκλίνει σε όρους κοινωνικών δικτύων και στα δύο μοντέλα.

1.2 A.2 — 4 λέξεις δικής μας επιλογής

Επιλέχθηκαν οι λέξεις *artificial*, *diffusion*, *efficiency*, *hysteria*.

Λέξη	word2vec (top-3)	GloVe (top-3)	Κοινές
artificial	artifical, Artificial, growth_hormone	synthetic, insemination, man-made	2/10
diffusion	dispersion, crystallinity, adsorption	gaseous, dispersion, viscosity	2/10
efficiency	efficiencies, efficency, Efficiency	efficient, efficiencies, improve	2/10
hysteria	mass_hysteria, paranoia, frenzy	paranoia, hysterical, euphoria	3/10

Παρατηρήσεις.

- Στο *artificial* το word2vec εμφανίζει **ορθογραφικά λάθη** (*artifical*) και τη μορφή με κεφαλαίο, πράγμα που αποκαλύπτει την επίδραση του «θορυβώδους» Google News corpus.
- Στο *diffusion* και τα δύο μοντέλα δίνουν φυσικοχημικές έννοιες· το word2vec έχει multi-word tokens (*catalytic_reaction*), το GloVe μόνο μονάδες λέξεων.
- Στο *efficiency* σχεδόν οι μισοί γείτονες του word2vec είναι **παραλλαγές με typos** (*efficency, effeciency, effiency, efficieny*), ενώ το GloVe επιστρέφει τις σωστές εννοιολογικά κοντινές λέξεις (*productivity, effectiveness*).
- Στο *hysteria* και τα δύο μοντέλα συγκλίνουν σε αρνητικά συναισθήματα (*paranoia, frenzy, mania*).

1.3 A.3 — Γειτονιές της λέξης *student* με αποκλεισμούς

Εξετάστηκαν **δύο μέθοδοι** αποκλεισμού:

- **Αλγεβρική**: *most_similar(positive=['student'], negative=[...])*.
- **Φιλτραρίσματος**: λήψη των top-200 γειτόνων του *student* και αποκλεισμός όσων έχουν cosine similarity > 0.5 με κάποια από τις λέξεις του seed-set εξαίρεσης.

Η αλγεβρική μέθοδος **αποτυγχάνει** όταν αφαιρούνται έννοιες που είναι κεντρικές στη λέξη-στόχο (π. χ. *university* αφαιρεθέν από *student* εκτοξεύει το διάνυσμα σε «θόρυβο»: επιστρέφονται tokens όπως *IF_SEPT*, *M.Kenseth_###*, *π2*). Η μέθοδος φιλτραρίσματος, αντιθέτως, παραμένει στην πυκνή περιοχή του χώρου των embeddings και παράγει ξεκάθαρες, αλληλο-αποκλειόμενες λίστες:

- **Χωρίς συσχέτιση με πανεπιστήμιο** — εμφανίζονται όροι σχολείου / νεαρών μαθητών: *teacher, classroom, classmates, pupils, youth, dorm*.
- **Χωρίς συσχέτιση με μαθητές Δημοτικού/Γυμνασίου/Λυκείου** — εμφανίζονται καθαρά πανεπιστημιακοί όροι: *faculty, undergraduate, university, campus, semester, academic, tuition*.

Συμπέρασμα. Η αλγεβρική αφαίρεση εννοιών είναι εύθραυστη όταν ο αποκλεισμός είναι κεντρικός στο query. Η μέθοδος pool-and-filter είναι πιο αξιόπιστη για παρόμοιες ερωτήσεις.

1.4 A.4 — 5 δοθείσες αναλογίες

Κάθε αναλογία επιλύεται ως *most_similar(positive=[a, c], negative=[b], topn=2)*. Το gensim εξαιρεί αυτόματα από το αποτέλεσμα τις 3 λέξεις της αναλογίας.

Αναλογία	**word2vec** (top-2)	**GloVe** (top-2)
$king - man + woman$	queen (0.71), monarch (0.62)	queen (0.67), princess (0.54)
$France - Paris + Tokyo$	Japan (0.82), Japanese (0.65)	japan (0.80), japanese (0.61)
$trees - apples + grapes$	oak_trees (0.68), vines (0.67)	vines (0.59), tree (0.58)
$swimming - walking + walked$	swam (0.69), swim (0.67)	swam (0.50), swimmers (0.49)
$doctor - father + mother$	nurse (0.71), doctors (0.66)	nurse (0.66), doctors (0.62)

Παρατηρήσεις.

- Η κανονική αναλογία *king* □ *queen* ανακτάται καθαρά και από τα δύο μοντέλα.
- Η σχέση *country–capital* (*France/Paris* □ *Japan/Tokyo*) είναι η πιο ισχυρή — υψηλότερες ομοιότητες (0.80–0.82).
- Η μορφολογική σχέση *ρήμα* □ *ρήμα* (*swimming* □ *swam*) λειτουργεί σωστά, με υψηλότερες ομοιότητες στο word2vec λόγω μεγαλύτερου corpus.
- Η αναλογία *doctor – father + mother* □ *nurse* αναπαράγει το γνωστό **gender bias** και στα δύο μοντέλα — επιβεβαιώνοντας ότι η προκατάληψη είναι ενσωματωμένη στο corpus, όχι στο μοντέλο.

1.5 A.5 — 3 αναλογίες δικής μας επιλογής

Αναλογία	**word2vec** (top-2)	**GloVe** (top-2)
$dollar - USA + Greece$	euro (0.59), greenback (0.56)	euro (0.54), currency (0.52)
$basketball - basket + feet$	football (0.45), ft (0.45)	meters (0.47), football (0.45)
$song - actor + acting$	songs (0.54), singing (0.53)	songs (0.56), singing (0.47)

Παρατηρήσεις.

- Στο *dollar – USA + Greece*, και τα δύο μοντέλα επιστρέφουν σωστά το *euro* (νόμισμα της Ελλάδας). Η εμφάνιση του *greenback* στο word2vec δείχνει ότι η αφαίρεση του *USA* δεν εξαλείφει πλήρως την «αμερικανικότητα».
- Στο *basketball – basket + feet*, και τα δύο μοντέλα ανακτούν το *football* (το άθλημα που παίζεται με τα πόδια). Οι runner-ups (*ft*, *meters*) είναι θόρυβος που προκύπτει από την **πολυσημία** του *feet* (μέρος του σώματος vs μονάδα μήκους).
- Στο *song – actor + acting*, στη δεύτερη θέση εμφανίζεται *singing* — η σωστή αναλογία (αν *acting* είναι η ενέργεια του *actor*, τότε *singing* είναι η ενέργεια του *singer*). Το *songs* στην πρώτη θέση είναι απλώς πληθυντικός — η μορφολογική γειτνίαση υπερισχύει της σημασιολογικής αναλογίας.

1.6 A.6 — Οπτικοποίηση t-SNE 28 λέξεων (GloVe)

Τα 300-διάστατα διανύσματα GloVe των 28 επιλεγμένων λέξεων προβλήθηκαν σε 2 διαστάσεις μέσω t-SNE (*perplexity=5*, *init='pca'*, *random_state=42*). Το αποτέλεσμα φαίνεται στο Σχήμα 1.1.

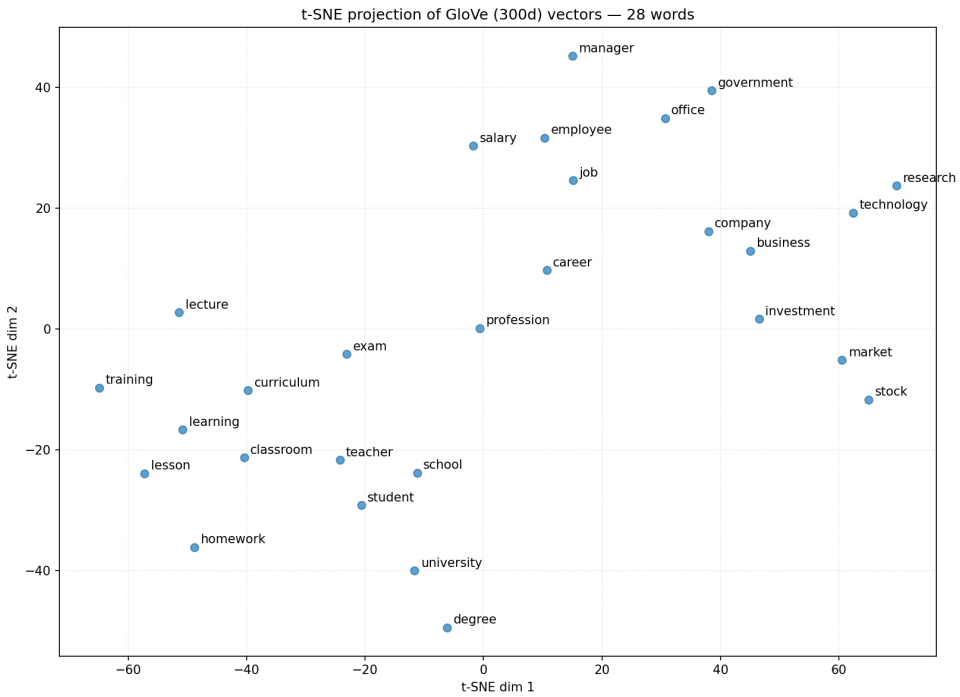

Σχήμα 1.1: t-SNE των 300d GloVe διανυσμάτων για 28 επιλεγμένες λέξεις.

Παρατηρήσεις. Διακρίνονται τρεις σαφώς διαχωρίσιμες σημασιολογικές ομάδες κατά μήκος του πρώτου άξονα t-SNE:

- **Εκπαίδευση** (αριστερά): *lesson*, *lecture*, *learning*, *curriculum*, *training*, *classroom*, *teacher* (επάνω) και *student*, *school*, *university*, *degree*, *homework*, *exam* (κάτω) — εσωτερική υπο-διάκριση μεταξύ «τι διδάσκεται» και «ποιος μαθαίνει».
- **Επιχειρήσεις / εργασία** (επάνω-δεξιά): *manager*, *employee*, *office*, *salary*, *job*, *company*, *business*, *government* — εργασιακή / θεσμική ορολογία.
- **Χρηματιστήριο / αγορές** (κάτω-δεξιά): *investment*, *market*, *stock* — η πιο απομονωμένη τριάδα.

Οι λέξεις-«γέφυρες» (*profession*, *career*, *research*, *technology*) τοποθετούνται στις διεπαφές μεταξύ ομάδων, αντικατοπτρίζοντας τη σημασιολογική τους διττότητα.

Κεφάλαιο 2

Μέρος Β — Παραδοσιακή ταξινόμηση κειμένου

Για το Μέρος Β χρησιμοποιήθηκε το *AG News Topic Classification dataset* (4 κατηγορίες: World, Sports, Business, Sci/Tech). Όλα τα κείμενα αναπαραστάθηκαν ως συνένωση τίτλου και περιγραφής (*Title + Description*).

2.1 Β.1 — Υλοποίηση των τεσσάρων μοντέλων

Υλοποιήθηκαν τέσσερα μοντέλα μέσω της βιβλιοθήκης *scikit-learn*:

- **Multinomial Naïve Bayes** με αναπαράσταση *tf-idf word uni-grams*.
- **Multinomial Naïve Bayes** με αναπαράσταση *tf-idf character tri-grams*.
- **Linear SVM** (γραμμικό kernel, $C = 1$) με αναπαράσταση *tf-idf word uni-grams*.
- **Linear SVM** (γραμμικό kernel, $C = 1$) με αναπαράσταση *tf-idf character tri-grams*.

Για το γραμμικό SVM χρησιμοποιήθηκε η κλάση *LinearSVC* αντί της *SVC(kernel="linear")*, καθώς η πρώτη υλοποιεί πιο αποδοτικό αλγόριθμο βελτιστοποίησης και είναι σημαντικά ταχύτερη για μεγάλα datasets όπως το AG News.

Το χρονικό κόστος εκπαίδευσης, περιλαμβάνει και την κατασκευή του λεξιλογίου tf-idf, καθώς αυτή είναι μέρος της εκπαίδευσης.

2.2 Β.2 — Συγκριτικός πίνακας επιδόσεων

	NB (word 1g)	**NB (char 3g)**	**SVM (word 1g)**	**SVM (char 3g)**
Accuracy	0.9022	0.8687	**0.9196**	0.9121
Dimensionality	64.999	31.074	64.999	31.074
Time cost (s)	0.96	4.46	3.31	13.76

Πίνακας 2.1: Επίδοση, διάσταση αναπαράστασης και χρονικό κόστος εκπαίδευσης των 4 μοντέλων στο AG News test set (7.600 κείμενα).

Παρατηρήσεις.

- Το **SVM υπερτερεί συστηματικά του Naïve Bayes** και για τις δύο μορφές αναπαράστασης, με διαφορά ∼1.7 μονάδες στα word uni-grams και ∼4.3 μονάδες στα char tri-grams. Ο διακριτικός χαρακτήρας του SVM (μεγιστοποίηση περιθωρίου) ξεπερνά τη γενετική προσέγγιση του NB που υποθέτει ανεξαρτησία χαρακτηριστικών.
- Τα **word uni-grams υπερτερούν των char tri-grams** και στις δύο οικογένειες ταξινομητών. Οι ειδήσεις του AG News είναι σύντομες και πλούσιες σε χαρακτηριστικές λέξεις-θεμάτων (*stocks*, *market*, *league*, *government*), όπου η αναπαράσταση λέξεων είναι ιδανική. Τα char n-grams βοηθούν περισσότερο όταν τα κείμενα έχουν ορθογραφικά λάθη, είναι πολύγλωσσα ή μορφολογικά πλούσια — το AG News δεν εμπίπτει σε καμία από αυτές τις περιπτώσεις.
- Η **βέλτιστη συνδυαστική επιλογή είναι το SVM με word uni-grams**, με ακρίβεια 91.96%.
- Παρότι τα char tri-grams δίνουν **μικρότερο λεξιλόγιο** (∼31 k έναντι ∼65 k), το SVM με αυτή την αναπαράσταση είναι το **αργότερο** (∼14 s έναντι ∼3 s για το word-SVM). Αυτό συμβαίνει επειδή τα char-tf-idf vectors είναι πυκνότερα ανά κείμενο (κάθε παράθυρο 3 χαρακτήρων αποτελεί χαρακτηριστικό), και ο coordinate-descent αλγόριθμος του LinearSVC είναι ευαίσθητος στην πυκνότητα.
- Το **Naïve Bayes είναι περίπου** 3× **ταχύτερο** του SVM για την ίδια αναπαράσταση, με κόστος ∼2 μονάδες ακρίβειας — αποδεκτή ανταλλαγή για production-style baselines.

2.3 B.3 — Ανάλυση σφαλμάτων: κείμενα που ταξινομούνται λανθασμένα από όλα τα μοντέλα

Από τα 7.600 κείμενα του test set, **341 (4,49%) ταξινομούνται λανθασμένα από όλα τα μοντέλα ταυτόχρονα**. Η κατανομή ανά κατηγορία φαίνεται στον Πίνακα 2.2.

Πραγματική κατηγορία	**Σφάλματα ομοφωνίας**
World	112
Sports	9
Business	135
Sci/Tech	85
Σύνολο	**341**

Πίνακας 2.2: Πλήθος κειμένων στο test set που ταξινομούνται λανθασμένα από **όλα** τα 4 μοντέλα, ανά πραγματική κατηγορία.

Παρατηρήσεις.

- Η κατηγορία **Sports** έχει με μεγάλη διαφορά τα λιγότερα ομόσφαλματα (μόλις 9). Το αθλητικό λεξιλόγιο (*game*, *team*, *coach*, *season*, *league*) είναι τόσο διακριτό ώστε ακόμη και το ασθενέστερο των τεσσάρων μοντέλων να το αναγνωρίζει σωστά.

- Η κατηγορία **Business** έχει τα περισσότερα ομόσφαλματα (135), ακολουθούμενη από **World** (112) και **Sci/Tech** (85). Οι κατηγορίες αυτές μοιράζονται σημαντική ορολογία — οικονομικές ειδήσεις περιέχουν συχνά πολιτικά / διεθνή στοιχεία (World), ενώ τεχνολογικές εταιρείες εμφανίζονται και στα Business και στα Sci/Tech.

Παράδειγμα σφάλματος. Στον Πίνακα 2.3 δίνεται ένα τέτοιο κείμενο (test index 24).

Πραγματική κατηγορία	Sci/Tech
Πρόβλεψη NB (word 1-grams)	Business
Πρόβλεψη NB (char 3-grams)	Business
Πρόβλεψη SVM (word 1-grams)	Business
Πρόβλεψη SVM (char 3-grams)	Business

Κείμενο: ``rivals try to turn tables on charles schwab by michael liedtke san francisco (ap) -- with its low prices and iconoclastic attitude, discount stock broker charles schwab corp. (sch) represented an annoying stone in wall street's wing-tipped shoes for decades...”

Πίνακας 2.3: Παράδειγμα κειμένου που και τα 4 μοντέλα ταξινόμησαν στην ίδια λάθος κατηγορία.

Πρόκειται για ένα άρθρο σχετικά με τη χρηματιστηριακή εταιρεία *Charles Schwab*, ταγμένο στο gold dataset ως *Sci/Tech*, αλλά και τα 4 μοντέλα το προβλέπουν ως *Business*. Το γεγονός ότι μοντέλα δύο διαφορετικών οικογενειών (NB vs SVM) και δύο πολύ διαφορετικών αναπαραστάσεων (λέξεων vs χαρακτήρων) συμφωνούν στη «λάθος» απάντηση αποτελεί ισχυρή ένδειξη ότι **το πραγματικό πρόβλημα δεν είναι αδυναμία των μοντέλων αλλά *label noise***, ασάφεια ή ασυνέπεια στην ίδια την ετικέτα του dataset.

Κεφάλαιο 3

Μέρος Γ — Ταξινόμηση κειμένου με RNNs / LSTMs

Στο Μέρος Γ υλοποιούνται έξι παραλλαγές αναδρομικών νευρωνικών δικτύων στο PyTorch και αξιολογούνται κυρίως στο *AG News* (όπως στο Μέρος Β) και τελικά στο *IMDB movie reviews dataset*. Όλες οι εκτελέσεις χρησιμοποιούν τις τιμές της εκφώνησης: *epochs=15*, *batch_size=1024*, *embedding_dim=100*, *hidden_dim=64*, *learning_rate=1e-3*, *min_freq=10*, με 3 ανεξάρτητες εκτελέσεις (*seeds=[0,1,2]*) για κάθε αρχιτεκτονική.

Η ενιαία κλάση *RecurrentClassifier* ενσωματώνει και τις 6 παραλλαγές μέσω τριών παραμέτρων (*rnn_type* $\in$ {rnn, lstm}, *num_layers* $\in \{1, 2\}$, *bidirectional* $\in$ {False, True}) και υποστηρίζει επιπλέον αρχικοποίηση από προ-εκπαιδευμένα embeddings, με δυνατότητα παγώματος.

3.1 Γ.1 --- Baseline grid (*MAX_WORDS=25*)

Έξι αρχιτεκτονικές $\times$ 3 seeds = 18 εκτελέσεις. Στον Πίνακα 3.1 παρατίθενται μέση ακρίβεια $\pm$ τυπική απόκλιση, αριθμός εκπαιδεύσιμων παραμέτρων και χρονικό κόστος ανά εποχή (μέσος όρος Apple-Silicon με MPS).

Metric	**1RNN**	**1Bi-RNN**	**2Bi-RNN**	**1LSTM**	**1Bi-LSTM**	**2Bi-LSTM**
Mean Accuracy	0.8841	**0.8862**	0.8828	0.8840	0.8798	0.8846
Std. Accuracy	0.0030	0.0057	0.0017	0.0010	0.0014	0.0023
Parameters	1.974.384	1.985.264	2.010.096	2.006.256	2.049.008	2.148.336
Sec / epoch	1.77	2.18	3.20	1.53	1.81	2.40

Πίνακας 3.1: Επίδοση των 6 αρχιτεκτονικών στο AG News test set, με τυχαία αρχικοποίηση των embeddings και *MAX_WORDS=25*.

Παρατηρήσεις.

- Όλες οι αρχιτεκτονικές συγκεντρώνονται σε μία ζώνη μόλις **0,6 μονάδων** (88,0--88,6%). Με σύντομο context (25 tokens) και embeddings που μαθαίνονται από το μηδέν, η επιλογή της αρχιτεκτονικής έχει αμελητέα επίπτωση.

- Ο αριθμός παραμέτρων κυριαρχείται από το embedding layer (∼1,96M = 19.635 tokens × 100), ενώ το αναδρομικό κελί προσθέτει 10--200k.
- Τα **LSTMs είναι ταχύτερα από τα αντίστοιχα RNNs** (1.53 s/ep έναντι 1.77 s/ep) χάρη στον βελτιστοποιημένο πυρήνα του PyTorch.
- Ως αναφορά, το καλύτερο μοντέλο του Μέρους Β (SVM word 1-grams) πετυχαίνει **0,9196** στο ίδιο dataset --- δηλαδή τα RNNs υστερούν εδώ κατά ∼3 μονάδες.

3.2 Γ.2 --- Σύγκριση CPU έναντι GPU

Τα μοντέλα 1RNN και 1LSTM εκτελέστηκαν σε CPU και σε GPU (NVIDIA T4 μέσω Google Colab) για 5 εποχές ανά εκτέλεση. Καταγράφηκε μόνο ο χρόνος ανά εποχή.

Model	CPU s/ep	CUDA s/ep	Speed-up
1RNN	10,61	3,63	2,9×
1LSTM	26,03	4,23	6,1×

Πίνακας 3.2: Χρονικό κόστος εκπαίδευσης ανά εποχή χωρίς και με χρήση επιταχυντή (NVIDIA T4 σε Colab).

Παρατηρήσεις.

- Η επιτάχυνση **κλιμακώνεται με την αριθμητική ένταση του μοντέλου**. Το LSTM έχει 4 πύλες ανά κελί, άρα 4× περισσότερους πολλαπλασιασμούς πινάκων ανά βήμα --- ο επιταχυντής δίνει **6,1**× βελτίωση. Το απλούστερο 1RNN, με μικρότερο υπολογιστικό φορτίο, βλέπει μικρότερη βελτίωση (2,9×), επειδή το per-step kernel-launch overhead αναλογικά κοστίζει περισσότερο.
- Το γενικό συμπέρασμα: *όσο μεγαλύτερο και αριθμητικά εντατικότερο το μοντέλο, τόσο μεγαλύτερη η ωφέλεια από επιταχυντή*. Για πολύ μικρά δίκτυα η CPU παραμένει ανταγωνιστική επιλογή.

3.3 Γ.3 --- Οπτικοποίηση t-SNE των embeddings που μαθαίνει το 1RNN

Στο Σχήμα 3.1 προβάλλονται μέσω t-SNE τα 100-διάστατα embeddings που έμαθε ένα 1RNN (15 εποχές, seed=0) για τις ίδιες 28 λέξεις του ερωτήματος A.6. Μία λέξη της λίστας (*curriculum*) δεν συμπεριλήφθηκε στο λεξιλόγιο του μοντέλου (εμφανίσεις < *min_freq=10*) και παραλείπεται.

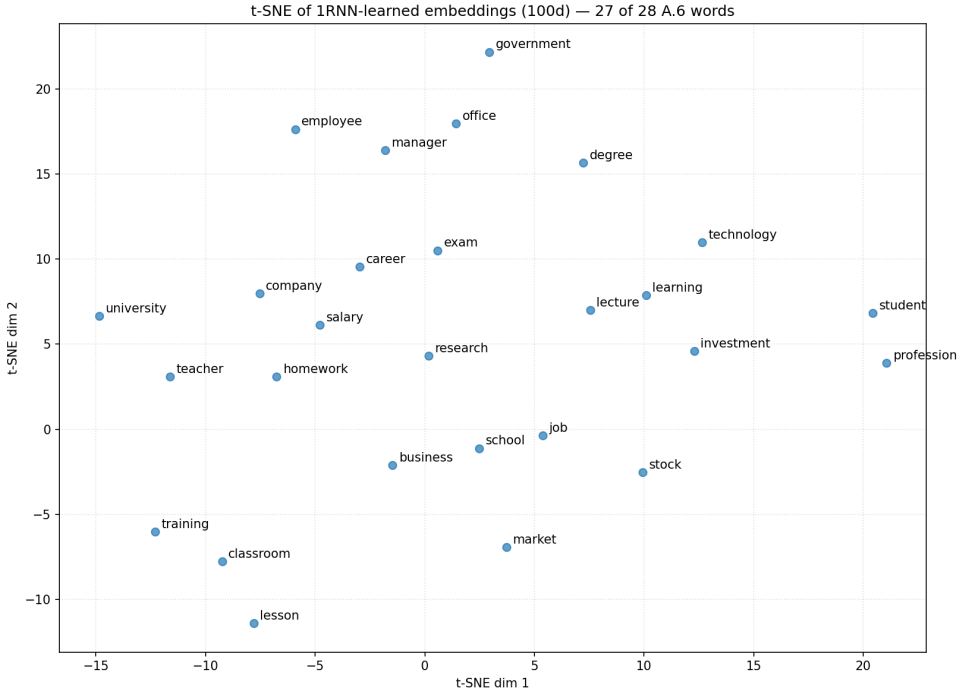

Σχήμα 3.1: t-SNE των embeddings που μαθαίνει το 1RNN, για 27 από τις 28 λέξεις του A.6.

Σύγκριση με το A.6 (GloVe). Το διάγραμμα του 1RNN είναι σαφώς **πιο διάχυτο** από αυτό του GloVe.

- Το **GloVe** εκπαιδεύτηκε σε δισεκατομμύρια tokens με στόχο τη συνεμφάνιση λέξεων (co-occurrence) --- επομένως κωδικοποιεί *γενική σημασιολογική ομοιότητα*.
- Το **1RNN** εκπαιδεύτηκε σε 120k κείμενα ειδήσεων με στόχο την *ταξινόμηση σε 4 κατηγορίες* --- τα embeddings μαθαίνουν μόνο όσο χρειάζεται για να διαχωρίσουν τις 4 κατηγορίες, όχι γενική σημασιολογία. Για λέξεις σπάνιες στο corpus ειδήσεων (*lesson*, *homework*, *lecture*), τα embeddings παραμένουν κοντά στην τυχαία αρχικοποίηση και το t-SNE δεν έχει σήμα να ανακτήσει.
- Παρ' όλα αυτά, εμφανίζεται μερική δομή στις λέξεις που είναι θεματικά κρίσιμες για το AG News: *stock* και *market* βρίσκονται κοντά (Business / Finance), όπως και το σύμπλεγμα *government*, *office*, *employee*, *manager* (World / Business).

Συμπερασματικά, *τα προ-εκπαιδευμένα embeddings είναι γενικής σημασιολογίας, ενώ τα task-trained είναι στενά εστιασμένα στο task.*

3.4 Γ.4 --- Επανάληψη με *MAX_WORDS=50*

Ίδιο grid με το Γ.1, αλλά με διπλάσιο μήκος ακολουθίας εισόδου.

Metric	1RNN	1Bi-RNN	2Bi-RNN	1LSTM	1Bi-LSTM	2Bi-LSTM
Mean Accuracy	0.8717	0.8968	0.8963	0.8998	0.9011	**0.9016**
Std. Accuracy	0.0113	0.0030	0.0028	0.0037	0.0014	0.0044
Parameters	1.974.384	1.985.264	2.010.096	2.006.256	2.049.008	2.148.336
Sec / epoch	2.26	3.17	5.26	1.81	2.76	4.14

Πίνακας 3.3: Επίδοση των 6 αρχιτεκτονικών στο AG News με *MAX_WORDS=50*.

Παρατηρήσεις.

- Το **απλό 1RNN χειροτερεύει** ($-1{,}24$ μονάδες σε σχέση με το Γ.1) και η τυπική απόκλιση εκτοξεύεται (από 0.003 σε 0.011, $\sim 4\times$). Πρόκειται για **κλασικό φαινόμενο vanishing gradients**: σε μακρύτερες ακολουθίες, ο αναδρομικός βρόχος δυσκολεύεται να μεταφέρει σήμα μέσω της οπίσθιας διάδοσης.
- Όλα τα **αμφίδρομα** μοντέλα βελτιώνονται κατά $+0{,}9$ έως $+2{,}1$ μονάδες. Οι πύλες των LSTMs επιτελούν ακριβώς τη λειτουργία για την οποία σχεδιάστηκαν: διατηρούν το σήμα του gradient σε μακρύτερες ακολουθίες.
- Τα **LSTMs ξεπερνούν τα RNNs** (διαφορά $\sim$3 μονάδες ανάμεσα στο καλύτερο LSTM και το χειρότερο RNN). Στο Γ.1 ήταν ισόπαλα --- εδώ οι πύλες κερδίζουν τη θέση τους.
- Το καλύτερο μοντέλο εκτοξεύεται από **0,8862** (1Bi-RNN @ 25) σε **0,9016** (2Bi-LSTM @ 50).
- Ο χρόνος ανά εποχή σχεδόν διπλασιάζεται, καθώς διπλασιάζεται το μήκος ακολουθίας αλλά οι παράμετροι παραμένουν αμετάβλητες.

3.5 Γ.5 --- Αρχικοποίηση από GloVe (trainable)

Ίδιες υπερπαράμετροι με το Γ.1, αλλά τα embeddings αρχικοποιούνται από το *glove-wiki-gigaword-100* (αντιστοίχιση token-προς-token με το λεξιλόγιό μας, OOV $\rightarrow$ μικρή τυχαία αρχικοποίηση, *<PAD>* $\rightarrow$ μηδενικό). Τα βάρη παραμένουν **εκπαιδεύσιμα** κατά τη διάρκεια της εκπαίδευσης.

Metric	1RNN	1Bi-RNN	2Bi-RNN	1LSTM	1Bi-LSTM	2Bi-LSTM
Mean Accuracy	0.8977	0.8954	0.8954	0.8991	**0.9016**	0.9005
Std. Accuracy	0.0027	0.0035	0.0016	0.0017	0.0030	0.0023
Parameters	1.974.384	1.985.264	2.010.096	2.006.256	2.049.008	2.148.336
Sec / epoch	1.78	2.15	3.16	1.48	1.75	2.54

Πίνακας 3.4: Επίδοση με αρχικοποίηση GloVe (trainable), *MAX_WORDS=25*.

Παρατηρήσεις.

- **Όλα τα μοντέλα κερδίζουν 1--2 μονάδες ομοιόμορφα** σε σχέση με το Γ.1, συνεπώς έχουμε ένα ομοιόμορφο όφελος. Μεγαλύτερο όφελος: **1Bi-LSTM (**$+2{,}18$**)**. Μικρότερο: **1Bi-RNN (**$+0{,}92$**)**.

- Το **1RNN κερδίζει σημαντικά** (+1,36): ο πιο αδύναμος βασικός εκπαιδευόμενος ωφελείται περισσότερο από το «προβάδισμα» που παρέχει η σωστή αρχικοποίηση.
- Όλα τα έξι μοντέλα παραμένουν συγκεντρωμένα σε ζώνη ∼0,6 μονάδων, όπως στο Γ.1, πρακτικά, η αλληλεπίδραση αρχιτεκτονικής και αρχικοποίησης είναι μικρή· σημασία έχει η ύπαρξη καλής αρχικοποίησης.
- Η τυπική απόκλιση γενικά μειώνεται, καθώς ένα warm-started μοντέλο έχει λιγότερο θόρυβο μεταξύ εκτελέσεων.
- Παράμετροι και χρόνος ανά εποχή είναι ουσιαστικά αμετάβλητοι σε σχέση με το Γ.1 (η αρχικοποίηση καθορίζει μόνο τις *αρχικές* τιμές).

3.6 Γ.6 --- Αρχικοποίηση από GloVe με frozen embeddings

Όπως το Γ.5, αλλά τα βάρη του embedding layer είναι **παγωμένα** (*requires_grad = False*). Εκπαιδεύονται μόνο τα αναδρομικά κελιά και ο γραμμικός ταξινομητής. Έτσι ο αριθμός εκπαιδεύσιμων παραμέτρων μειώνεται κατά ∼1,96M.

Metric	1RNN	1Bi-RNN	2Bi-RNN	1LSTM	1Bi-LSTM	2Bi-LSTM
Mean Accuracy	0.8833	0.8867	0.8893	0.9030	0.9075	**0.9086**
Std. Accuracy	0.0022	0.0010	0.0029	0.0036	0.0022	0.0003
Parameters	10.884	21.764	46.596	42.756	85.508	184.836
Sec / epoch	1.67	2.10	3.05	1.41	1.64	2.28

Πίνακας 3.5: Επίδοση με GloVe init και **παγωμένο** embedding layer, *MAX_WORDS=25*.

Παρατηρήσεις. Πρόκειται για το πιο εντυπωσιακό αποτέλεσμα του Μέρους Γ:

- Οι εκπαιδεύσιμες παράμετροι μειώνονται από ∼2M σε 10k--185k --- μείωση **10--200**×.
- **Τα RNNs χάνουν, τα LSTMs κερδίζουν** από το πάγωμα:
  - *Κανονικοποίηση*: όταν τα embeddings είναι trainable, μπορούν να «ξεμακρύνουν» από τη σωστή τους αρχικοποίηση και να υπερκεράσουν το προβάδισμα του GloVe. Το πάγωμα διατηρεί την καθαρή σημασιολογία.
  - *Έκφραση κελιού*: οι πύλες των LSTMs είναι αρκετά εκφραστικές για να εξάγουν task-σχετικό σήμα από *σταθερές* εισόδους· τα απλά κελιά RNN δεν είναι και χρειάζονται τα embeddings να αναλάβουν μέρος του διαχωριστικού έργου.
- Το **2Bi-LSTM είναι αναμφίβολα ο νικητής** με 0,9086 ± 0,0003, το **καλύτερο αποτέλεσμα όλου του Μέρους Γ**. Η τυπική απόκλιση επίσης καταρρέει: τα παγωμένα embeddings αφαιρούν μία σημαντική πηγή θορύβου.
- Το χρονικό κόστος ανά εποχή μειώνεται ελαφρώς (5--15%), καθότι δεν υπολογίζεται gradient για 1,96M παγωμένες/frozen παραμέτρους.

3.7 Γ.7 --- Επανάληψη του Γ.1 στο IMDB

Ίδιο grid με το Γ.1 αλλά στο *IMDB* (50.000 κριτικές ταινιών, 2 κατηγορίες), με ντετερμινιστικό 80/20 split (40.000 / 10.000). *MAX_WORDS=25* όπως ορίζει το αντίστοιχο πλαίσιο (στις 250 λέξεων κατά μέσο όρο κριτικής, βλέπουμε μόνο τα **πρώτα 25 tokens**).

Metric	1RNN	1Bi-RNN	2Bi-RNN	1LSTM	1Bi-LSTM	2Bi-LSTM
Mean Accuracy	**0.7162**	0.7017	0.7016	0.7147	0.7099	0.7064
Std. Accuracy	0.0032	0.0006	0.0017	0.0063	0.0064	0.0013
Parameters	2.552.054	2.562.806	2.587.638	2.583.926	2.626.550	2.725.878
Sec / epoch	1.69	1.81	2.13	1.65	1.72	1.85

Πίνακας 3.6: Επίδοση των 6 αρχιτεκτονικών στο IMDB (80/20 split, *MAX_WORDS=25*).

Παρατηρήσεις.

- Η ακρίβεια κατρακυλά στο 70--72% --- πολύ κάτω από το AG News (∼88--90%). Δύο λόγοι:
  - Με *MAX_WORDS=25* βλέπουμε μόνο ∼10% κάθε κριτικής. Τα κρίσιμα στοιχεία συναισθήματος (αρνήσεις, αντιθέσεις, καταληκτικά μηνύματα) χάνονται στο τέλος της κριτικής που δεν δειγματίζουμε.
  - Το συναίσθημα είναι *αντικειμενικά πιο δύσκολο* από τη θεματική: «match / coach / league» εγγυάται *Sports*, αλλά «θετικό vs αρνητικό» συχνά εξαρτάται από μία φράση όπως «...αλλά τελικά απογοητευτικό».
- Έκπληξη: **το απλό 1RNN νικά ή ισοφαρίζει κάθε gated ή αμφίδρομη παραλλαγή** (0,7162 έναντι 0,70--0,71). Με 25 tokens δεν υπάρχει πραγματικά «ακολουθία» να μοντελοποιηθεί και συνεπώς κάθε αρχιτεκτονική κάνει ουσιαστικά **bag-of-words ταξινόμηση**, και το απλούστερο κελί νικά.
- Bidirectional και 2 layers δεν προσφέρουν, καθότι δεν υπάρχει μακρού εύρους δομή να εκμεταλλευτούν σε 25 tokens.
- Το λεξιλόγιο είναι **μεγαλύτερο από αυτό του AG News** με ίδιο *min_freq=10* (∼25,5k έναντι ∼19,6k): οι κριτικές ταινιών χρησιμοποιούν πλουσιότερο λεξιλόγιο, οπότε οι παράμετροι ανεβαίνουν στα 2,5--2,7M.
- Για να ελέγξει πραγματικά κανείς την ικανότητα μοντελοποίησης ακολουθιών στο IMDB, θα χρειαζόταν *MAX_WORDS=200+*.